

ТЕХНИЧЕСКОЕ ЗАДАНИЕ

1. Общие сведения

Заказчик: АО Народный Банк Казахстана

Хакатон: HackAlem AI

Трек: Halyk Bank

Название задачи: AI для корпоративных продуктов

Тип задачи: Product-разработка, AI/LLM-engineering, Full-stack

Инструменты: Разрешено использовать любые модели и сервисы: облачные и локальные LLM, STT, TTS.

2. Проблема

Компания ведёт два потока коммуникаций - внутрь, с сотрудниками, и наружу, с клиентами. Оба работают на устаревшей логике.

Внутренний контур

Карьера сотрудника - это десятки событий: онбординг, обучение, аттестации, менторство, ротации. Они доходят до человека разрозненными уведомлениями с дедлайнами. Сотрудник не видит траектории и не понимает, что ему даст конкретная активность, поэтому проходит всё формально. Компания расходует бюджет на развитие полностью, но получает низкую завершаемость программ и слабую явку на добровольные активности.

Внешний контур

Голосовые роботы научились хорошо говорить и слышать. Но слой, выбирающий сценарий разговора, у большинства систем остаётся классификатором на энкодерной модели — обученным на фиксированных формулировках и ломающимся там, где начинается живая речь: смена темы посреди диалога, запрос между двумя сценариями, переход с русского на казахский внутри фразы. Каждый неверный выбор — перевод на оператора или потерянный клиент.

Общее у двух задач: узкое место не в технологии, а в слое принятия решения. И в обоих случаях его сегодня можно построить на LLM, понимающей контекст, а не сопоставляющей формулировки с обучающей выборкой.

3. Стейкхолдеры

Пользователи: сотрудники компании; HR-специалисты и руководители подразделений; клиенты контакт-центра; операторы и супервизоры.

Ключевые боли:

- Как объяснить сотруднику, зачем ему конкретная активность и куда она ведёт?
- Как сделать профессиональный рост видимым, чтобы он мотивировал?
- Как научить робота понимать клиента, говорящего живым языком?
- Как сделать это, не убив скорость — пауза дольше секунды в разговоре читается как сбой связи.

4. Выбор кейса

- **Кейс 1: Career Quest** - AI-навигатор развития сотрудника.

- **Кейс 2: Voice Router** - голосовой робот с AI-слоем выбора сценария

КЕЙС: VOICE ROUTER

- 1) Название. Voice Router - гибридный голосовой AI-робот с LLM-слоем выбора сценария.
- 2) Проблема. Клиент контакт-центра сталкивается с роботом, который хорошо говорит и слышит, но выбирает сценарий классификатором на энкодерной модели, из-за чего при смене темы, запросе на стыке сценариев или переходе между русским и казахским разговор уходит не туда: клиент переводится на оператора и в части случаев уходит вовсе.
- 3) Пользователь. Клиент контакт-центра: говорит своими словами → робот с первой реплики понимает суть и запускает нужный сценарий → при смене темы переключается, не теряя контекст → вопрос закрывается без оператора. Второй пользователь - супервизор: видит, какие сценарии выбирались, где робот сомневался и ошибся.
- 4) Задача. Разработать голосового AI-робота с веб-интерфейсом симуляции, который заменяет классификатор намерений на LLM-слой, понимающий контекст диалога, и выдаёт голосовой ответ клиенту плюс трассировку для супервизора: какой сценарий выбран, почему, за какое время.

Оценивается качество маршрутизации, а не качество синтеза и распознавания речи. Скорость — отдельный измеряемый показатель, дающий дополнительные баллы.

- 5) Вход: Вход: голосовая речь через микрофон, текст как резервный канал. Русский и казахский, включая переключение внутри диалога. Пример: «Здравствуйте, я вчера оплатил, деньги списались, а заказ не подтвердился... а, и ещё, адрес доставки поменять надо». Объём: 40 сценариев, диалог до 10 реплик.
- 6) Выход: голосовой ответ и панель трассировки — транскрипт, выбранный сценарий с обоснованием, альтернативы, замер задержки по этапам. Допустимая задержка: ориентир по выбору сценария — 500 мс, от конца реплики до начала ответа — 1,5 секунды. Замеры отображаются в интерфейсе и учитываются в баллах, но не являются условием сдачи.
- 7) Данные и инструменты. Способ доступа: стартовый кит, выдаётся в день хакатона.

Состав:

— scenarios.json — 40 сценариев: назначение, границы с соседними сценариями, параметры, действия, примеры запросов и ответов на русском и казахском

— dialogs_sample.json — 10 размеченных примеров диалогов, включая смену темы и смешанную речь

— knowledge_base.json, mock_backend.json — факты о компании и тестовые клиенты для ответов

— dev_utterances.json и evaluate.py — размеченные реплики и скрипт для самостоятельного замера точности

Использование собственных моделей допускается, но преимуществом при оценке не является: кейс про маршрутизацию, а не про соревнование речевых моделей.

Компания в данных вымышленная (страховая), подробное описание в README стартового кита. 10 проверочных реплик с ожидаемыми сценариями хранятся у жюри и командам не выдаются.

Ограничения: каталог обезличен, реальных клиентских данных не содержит. Расширение собственными сценариями разрешено, оценка идёт по исходным сорока.

8) Must-have

Требование	Проверка
Голосовое взаимодействие в вебе	Жюри говорит в микрофон - робот распознаёт и отвечает голосом. Текст только как дополнение
Выбор сценария на LLM-слое	Команда показывает устройство слоя. Intent-классификатор энкодерного типа не засчитывается
Корректность выбора	Жюри зачитывает 10 одинаковых для всех реплик - простые, со сменой темы, смешанной речью, на стыке сценариев. Считается доля попаданий
Панель трассировки	После каждой реплики виден сценарий, обоснование, альтернативы, время по этапам
Русский и казахский	Две реплики набора на казахском, одна со смешением языков внутри фразы

9) Опционально. Гибридная архитектура — быстрый путь для очевидных запросов, LLM для сложных, с измеримым выигрышем по задержке; достижение ориентира в 500 мс; удержание контекста и возврат к прерванной теме; переспросить вместо угадывания и передать оператору вместе с контекстом; извлечение параметров из речи; потоковая обработка; определение эмоции и подстройка тона; панель супервизора со статистикой ошибок; редактирование каталога без разработчиков.

10) Ограничения.

Нельзя: выбор сценария на готовом intent-классификаторе — ровно та архитектура, от которой уходит кейс. Хардкод сопоставления проверочных реплик со сценариями. Реальные записи разговоров.

Учесть:

- Приватность: данные синтетические; внешние API (LLM, STT, TTS) разрешены, реальные персональные данные в них не передаются
- Безопасность: робот не выполняет необратимых действий без подтверждения клиента
- Explainability: супервизор видит логику, а не голый вердикт
- Инфраструктура: запуск одной командой
- Производительность: задержка измеряется и даёт дополнительные баллы, но не снижает основную оценку

5. Минимальные требования

Решение принимает реальный пользовательский ввод, обрабатывает его с применением LLM в точке содержательного решения, а не для косметической генерации текста, возвращает результат с объяснением и работает на данных, а не на записанном демо-сценарии.

AI помогает человеку, а не подменяет его. В кейсе 1 решение о развитии остаётся за сотрудником и руководителем. В кейсе 2 робот обязан передавать разговор оператору там, где не справляется.

6. Жёсткие ограничения

- AI не является единственным источником истины; где модель не уверена - она это показывает

- Решения должны быть объяснимыми

- Не принимаются: «чёрный ящик»; демо на одном подготовленном сценарии; решения без реальной обработки данных; публичные рейтинги сотрудников (кейс 1); выбор сценария на intent-классификаторе (кейс 2)

7. Что ценится

Продуктовость - пользователь работает без объяснений от разработчика. Объяснимость. Масштабируемость архитектуры. Учёт ограничений домена, а не только технической стороны: психология мотивации в кейсе 1, темп живого разговора в кейсе 2. Честное обозначение границ применимости.

8. Артефакты. Репозиторий: да. README: да.

Критерий	Что оцениваем	Баллы
Соответствие задаче и работоспособность	Оценивается, насколько решение соответствует поставленной задаче и позволяет реализовать основной заявленный сценарий.	25
Техническая реализация	Оценивается качество технической реализации решения: выбранный подход, архитектура, взаимодействие компонентов, использование AI/agentic AI и других технологий. Учитывается соответствие фактической реализации заявленной логике проекта.	25
README и воспроизводимость	Оценивается, насколько документация позволяет понять устройство проекта, используемые технологии, порядок запуска и основной сценарий работы. Также учитывается возможность воспроизвести и проверить решение на основании материалов репозитория.	25
Ценность и применимость решения	Оценивается, насколько решение отвечает обозначенной проблеме. Учитывается практическая применимость представленного подхода.	15
Потенциал развития и оригинальность подхода	Оценивается потенциал дальнейшего развития решения, его применения в более широком масштабе, а также наличие обоснованных нестандартных или оригинальных подходов к реализации задачи.	10
Итого	—	100